

Прогнозирование охвата и частоты рекламной кампании в аукционной системе VK Ads

Тематика программы: машинное обучение, анализ данных, рекламные технологии.

Направление: campaign performance forecasting и reach/frequency forecasting в аукционных рекламных системах.

Актуальность

Задача прогнозирования охвата рекламной кампании важна для рекламных платформ и рекламодателей, поскольку до запуска кампании необходимо оценивать не только ожидаемый объем показов, но и распределение контактов внутри целевой аудитории.

Один и тот же суммарный объем показов может соответствовать разным сценариям: много пользователей увидели рекламу один раз или небольшая группа пользователей получила несколько повторных контактов. Поэтому метрики 1+, 2+ и 3+ являются практически значимыми для планирования охвата и частоты.

Задача усложняется тем, что показы формируются через рекламный аукцион. На результат влияют ставка CPM, время запуска кампании, площадки, активность пользователей, доступный рекламный инвентарь и правило пользовательских сессий.

Обзор предметной области

Работа находится на пересечении нескольких направлений: прогнозирования эффективности рекламных кампаний, оценки охвата и частоты, а также моделирования рекламных аукционов.

1. Campaign performance forecasting

В современных работах по campaign performance forecasting, например AdVance, основное внимание уделяется прогнозированию агрегированных показателей кампании: стоимости, числа показов, кликов и конверсий. Такие модели используют богатые внутренние логи рекламных платформ: последовательности аукционов, клики, конверсии, candidate ads и поведенческие признаки пользователей.

Отличие данной работы состоит в другой целевой переменной: прогнозируются не агрегированные KPI кампании, а threshold reach - доли пользователей, получивших не менее 1, 2 и 3 показов.

2. Reach/frequency forecasting и frequency capping

В работах по reach measurement и frequency capping изучаются охват, частота контактов и ограничения на число показов одному пользователю. Это близко к рассматриваемой задаче по смыслу, однако чаще формулируется как задача измерения, оптимизации или ограничения частоты, а не как прогноз будущей кампании по ограниченным открытым аукционным логам.

3. Auction simulation

Работы по auction simulation, включая AuctionNet-подобные подходы, рассматривают моделирование рекламных аукционов и поведения bidding-стратегий. Они полезны как методологическая опора, но решают другую задачу: симуляцию или оптимизацию ставок, а не прогноз долей пользователей с 1+, 2+ и 3+ контактами.

Итог обзора

Ближкие направления существуют, но точная публичная постановка с прогнозом $P(N \geq 1)$, $P(N \geq 2)$, $P(N \geq 3)$ при ограниченных VK-like auction logs встречается редко. Поэтому вклад работы состоит в адаптации идей прогнозирования рекламных кампаний к задаче threshold reach forecasting с жёстким контролем data leakage.

Для фиксации новизны работа сопоставлялась не только по названию темы, но и по типу данных, целевой переменной и воспроизводимости постановки.

Направление	Что решает	Связь с работой	Отличие данной задачи
AdVance / campaign forecasting	Прогноз KPI кампаний: показы, клики, конверсии, стоимость.	Показывает актуальность прогнозирования рекламной эффективности.	Цель здесь не KPI кампании, а доли пользователей с 1+, 2+ и 3+ контактами; в открытых данных нет кликов, креативов и полных auction logs.
Reach measurement и frequency capping	Оценка охвата, частоты и ограничение повторных контактов.	Близкая предметная логика: важно распределение контактов по пользователям.	Чаще решается измерение или оптимизация частоты, а не прогноз будущей кампании по ограниченной истории показов.
Auction simulation / AuctionNet	Симуляция аукциона, bidding-стратегий и рекламной среды.	Даёт методологическую опору для учёта правил аукциона.	Фокус на симуляции и ставках; итоговая цель не threshold reach по заданной аудитории.
Данная работа	Прогноз at_least_one, at_least_two, at_least_three для будущей кампании.	Объединяет историю показов, CPM-аукцион, сессии и агрегацию вероятностей.	Постановка сделана для ограниченных VK-like логов и строгой temporal validation без data leakage.

Постановка задачи

На вход подаются параметры будущей рекламной кампании: CPM, час начала и окончания, список площадок, размер аудитории и идентификаторы пользователей. Дополнительно доступны история показов и базовые пользовательские признаки.

На выходе необходимо предсказать три величины:

- at_least_one - доля пользователей, увидевших объявление хотя бы один раз;
- at_least_two - доля пользователей, увидевших объявление хотя бы два раза;

- `at_least_three` - доля пользователей, увидевших объявление хотя бы три раза.

Формально для пользователя u из аудитории A рассматривается случайная величина N_u - число показов объявления этому пользователю. Тогда целевые значения задаются как средние вероятности по аудитории:

$$at_least_k = (1 / |A|) * \sum_{u \in A} P(N_u \geq k), \quad k \in \{1, 2, 3\}$$

Метод

В качестве основной модели выбран декомпозиционный replay-подход. Его идея состоит в том, чтобы не прогнозировать итоговый охват напрямую, а отдельно смоделировать исторический рекламный инвентарь, правила аукциона, пользовательские сессии и агрегацию вероятностей.

Правило выигрыша аукциона

Для каждого исторического события сравнивается CPM прогнозируемой кампании с winning CPM в истории. Вероятность выигрыша задаётся правилами задачи:

$$P(\text{win}) = 1, \quad \text{если } cpm_campaign > cpm_history$$

$$P(\text{win}) = 0.5, \quad \text{если } cpm_campaign = cpm_history$$

$$P(\text{win}) = 0, \quad \text{если } cpm_campaign < cpm_history$$

Учет пользовательских сессий

Система не показывает пользователю одно и то же объявление повторно внутри одной сессии. Новая сессия начинается после шести часов без показов. Поэтому показы сначала агрегируются на уровне пользовательских сессий, а затем для каждого пользователя вычисляется распределение числа выигранных сессий.

$$P_u(0) = \prod_{s \in S_u} (1 - p_s)$$

$$P_u(N \geq 1) = 1 - P_u(0)$$

$$P_u(N \geq 2) = 1 - P_u(0) - P_u(1)$$

$$P_u(N \geq 3) = 1 - P_u(0) - P_u(1) - P_u(2)$$

Значения $P_u(1)$ и $P_u(2)$ вычисляются через Poisson-binomial динамическую агрегацию по вероятностям пользовательских сессий.

Исторические окна и blend

Чтобы учесть разные временные масштабы, используются несколько past-only исторических компонент: `monthly`, `daily` и `weekly`. Итоговый прогноз получается геометрическим blend в лог-пространстве, что согласовано с логарифмической метрикой качества.

$$y_hat = \exp(w_m \log(y_m + \epsilon) + w_d \log(y_d + \epsilon) + w_w \log(y_w + \epsilon)) - \epsilon$$

Финальная конфигурация: daily_lags = 8, weekly_lags = 5, веса monthly/daily/weekly = 0.05 / 0.40 / 0.55, bias-калибровка отключена.

Защита от data leakage

Для временных рекламных данных особенно важно не использовать информацию из будущего. В работе реализован строгий validation protocol:

- temporal split по времени запуска кампаний;
- использование только past-only признаков и окон;
- запрет на replay целевых часов validate;
- отдельный locked final holdout;
- фиксация прогноза и SHA-256 перед расчётом финальной метрики.

Открытая validation-выборка частично пересекается с history по времени, поэтому наивное использование history до каждого hour_start дало бы более низкую метрику, но не соответствовало бы hidden-test постановке. В финальной оценке используется строгий test-like режим: история режется до первого часа validate.

Потенциальный риск	Как закрыт в работе	Зачем это важно
Использование будущих показов	История ограничена cutoff до начала validate; признаки строятся только из прошлого.	Иначе модель видит будущий рекламный инвентарь и получает завышенную метрику.
Подбор весов на финальном тесте	Выбор конфигурации выполнен на development/calibration/pretest; final holdout закрыт до финального расчёта.	Финальная оценка остаётся проверкой обобщения, а не результатом ручной подгонки.
Повторные показы внутри сессии	История агрегируется в пользовательские сессии с правилом 6 часов.	Без этого частота контактов переоценивается, особенно для активных пользователей.
Сравнение с моделями из статей	Проводится концептуально по постановке, данным и целям, а не как прямой численный benchmark.	В статьях используются другие закрытые данные и другие целевые переменные.

Базовые модели и эксперименты

Эксперименты были выстроены как последовательное усиление baseline: от простого исторического шаблона к декомпозиции по временным окнам, затем к калибровке и сравнению с ML-моделями. Такой дизайн позволил не только получить лучший скор, но и объяснить, почему финальная модель является более устойчивой.

Ключевые проверенные варианты:

- monthly replay baseline - прогноз по похожему окну прошлого месяца;
- daily replay - несколько последних дневных окон для учёта коротких изменений спроса;
- weekly replay - недельные лаги для сезонности по дням недели и часам;
- geometric blend - объединение monthly/daily/weekly компонент в лог-пространстве;

- target-wise diagnostics - отдельный подбор компонент для 1+, 2+ и 3+ как проверка чувствительности таргетов;
- градиентный бустинг на агрегированных признаках пользователей, кампании и истории;
- бустинг с replay/decomposition features как сильный ML-baseline;
- нейросетевая multi-task постановка с общим представлением и отдельными головами для трёх таргетов.

Эксперименты с replay-декомпозицией

Этап	Проверка	Метрика отбора	Final holdout	Вывод
1	Monthly replay baseline.	11.77% temporal; 11.55% с rolling calibration	11.70%	Честный baseline, но плохо ловит краткосрочные изменения инвентаря.
2	Daily replay: несколько последних дневных окон.	9.53% purged OOF	не финальная модель	Улучшает baseline за счёт актуального спроса и свежей активности.
3	Weekly replay: похожие дни недели и часы.	9.87% purged OOF	не финальная модель	Добавляет недельную сезонность, но отдельно слабее blend.
4	Geometric blend monthly/daily/weekly.	9.46% purged OOF; 8.03% calibration; 8.17% pretest	9.54%	Финальная модель: лучшая устойчивость на закрытом temporal holdout.
5	Target-wise blend и past-median calibration.	9.43% purged OOF; target log-error diagnostics	не финальная модель	Полезно как диагностика, но финально выбран более простой устойчивый scalar blend.

ML-baselines и проверка усложнения модели

Этап	Проверка	Метрика отбора	Final holdout	Вывод
6	Gradient boosting на user/history/campaign aggregates.	12.78% temporal для HGB; 16.33-27.67% в строгих вариантах	30.89%	Без replay-логики табличная модель плохо переносится во времени.
7	Boosting + replay/decomposition features.	6.61% calibration; 6.92% pretest	10.94%	Сильный pretest, но хуже final holdout: признак переобучения на режим валидации.
8	Multi-task MLP с общим представлением и головами для 1+, 2+ и 3+.	38.12% temporal	не финальная модель	Близко к современным статьям концептуально, но в текущих ограниченных логах нестабильно.

Главный вывод из экспериментов: простая ML-модель на агрегатах не заменяет механистическую декомпозицию. Для этой постановки критично явно учитывать правило выигрыша CPM-аукциона, сессионность и temporal split. Поэтому финальная модель выбрана не только по минимальной промежуточной метрике, но и по устойчивости между calibration, pretest и locked final holdout.

Метрика качества

Использовалась официальная метрика задачи - Smoothed Mean Log Accuracy Ratio. Она оценивает относительное расхождение между предсказанными и фактическими долями пользователей по трём таргетам.

$$\text{Score} = 100\% * (\exp((1 / (3n)) * \sum_{i=1..n} \sum_{j=1..3} |\log((\text{Pred}_{ij} + \text{eps}) / (\text{Actual}_{ij} + \text{eps}))|) - 1)$$

Здесь $\text{eps} = 0.005$. Сглаживание нужно, чтобы метрика была устойчивой при малых фактических долях. Чем ниже значение метрики, тем лучше качество прогноза.

Результаты

Итоговое сравнение проводилось на locked final holdout. Метрика минимизируется: чем ниже значение, тем точнее прогноз долей 1+, 2+ и 3+.

Модель	Что использует	Final metric	Интерпретация
Monthly baseline	Исторический шаблон прошлого месяца.	11.70%	Честная нижняя планка качества для сезонного replay-подхода.
Boosting + replay features	190 агрегированных и replay-признаков; обучение на pretest.	10.94%	Сильный ML-baseline, но хуже переносится на финальный будущий период.
Static/history boosting	64 агрегированных признака без полноценной replay-декомпозиции.	30.89%	Показывает, что одних табличных агрегатов недостаточно.
Финальная декомпозиционная модель	CPM-аукцион, сессии, daily/weekly/monthly replay и геометрический blend.	9.54%	Лучший и наиболее устойчивый результат; улучшение monthly baseline примерно на 18%.

Итоговая модель улучшила monthly baseline примерно на 18% относительно и примерно на 13% относительно лучшего boosting baseline. Важный практический вывод: в этой задаче качество даёт не усложнение модели само по себе, а правильная декомпозиция механизма показа рекламы.

Почему не использовалась предобученная модель

Использование внешней предобученной модели в данной постановке не является методологически обоснованным. В датасете отсутствуют тексты объявлений, изображения креативов, клики, конверсии, идентификаторы объявлений и полные auction logs. Поэтому невозможно корректно применить универсальную pretrained модель или воспроизвести модели из статей, обученные на закрытых логах рекламных платформ.

Вместо этого выбран интерпретируемый подход, основанный на механизме формирования показов: истории рекламного инвентаря, правилах CPM-аукциона и пользовательских сессиях.

Выводы

В работе построена воспроизводимая модель прогнозирования охвата и частоты рекламной кампании в аукционной системе. Модель явно учитывает механизм формирования показов и защищена от утечек из будущего.

Академический вклад работы состоит в адаптации идей campaign performance forecasting к задаче threshold reach forecasting при ограниченных аукционных логах. Практический результат - улучшение качества прогноза относительно исторического baseline и ML-baseline на строгой temporal validation.

Ограничения и перспективы

Основные ограничения связаны с неполнотой данных: отсутствуют проигравшие ставки, клики, конверсии, признаки креативов и идентификаторы объявлений. Поэтому прямое численное сравнение с современными статьями, такими как AdVance, невозможно; сравнение проводится концептуально по постановке задачи, данным и подходам.

Дальнейшее развитие работы может включать:

1. добавление признаков объявлений, креативов, кликов и конверсий при наличии данных;
2. проверку multi-task нейросетевой модели с общим представлением и отдельными головами для 1+, 2+ и 3+;
3. отдельную калибровку вероятностей для каждого таргета;
4. сравнение с моделями на полных auction logs при доступе к закрытым логам рекламной платформы.

Использованные источники

- Wang et al. Know in AdVance: Linear-Complexity Forecasting of Ad Campaign Performance with Evolving User Interest, 2024. <https://arxiv.org/abs/2405.10681>
- Gao, Qiao. Reach Measurement, Optimization and Frequency Capping in Online Advertising, 2025. <https://arxiv.org/abs/2501.04882>
- AuctionNet: benchmarking and simulation approaches for advertising auctions, 2024. <https://arxiv.org/abs/2412.10798>
- Arrate et al. Large-scale analysis of user exposure to online advertising in Facebook, 2018. <https://arxiv.org/abs/1811.10921>